

# Comparação de Arquiteturas de Redes Neurais

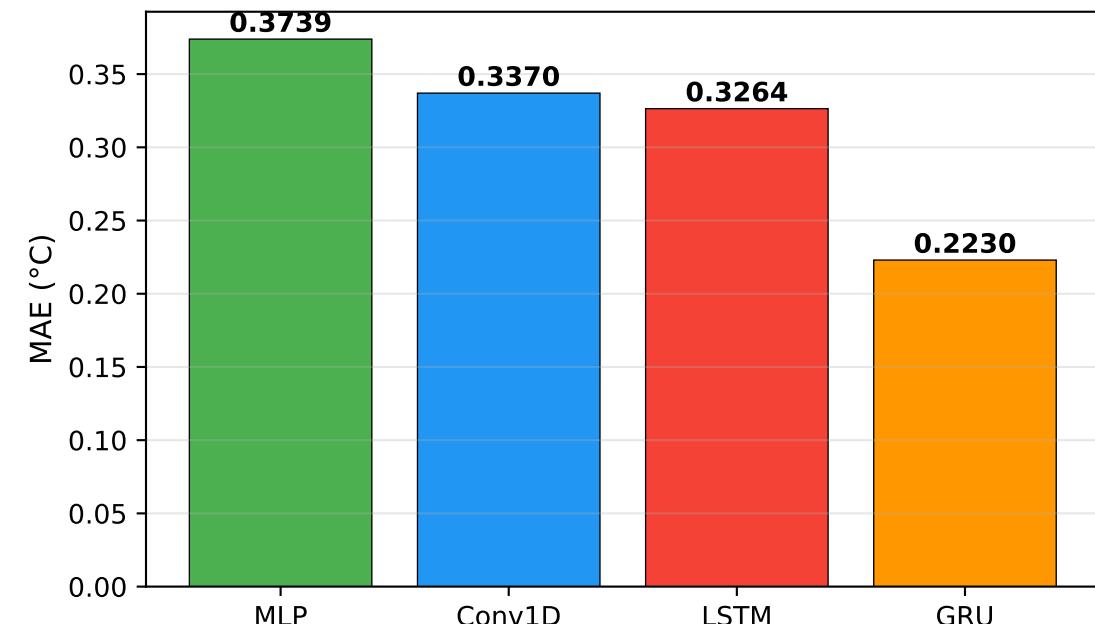
Predição de Temperatura - TinyML para Raspberry Pi Pico (RP2040)

Métrica	MLP	Conv1D	LSTM	GRU
<b>Parâmetros</b>	1.891	1.963	3.235	2.611
<b>MAE Geral (°C)</b>	0.3739	0.3370	0.3264	0.2230 ★
<b>RMSE (°C)</b>	0.4618	0.4404	0.3913	0.2978 ★
<b>R<sup>2</sup></b>	0.9834	0.9849	0.9881	0.9931 ★
<b>MAE 5 min (°C)</b>	0.3535	0.2908	0.2987	0.1784 ★
<b>MAE 10 min (°C)</b>	0.3706	0.3314	0.3173	0.2164 ★
<b>MAE 15 min (°C)</b>	0.3976	0.3887	0.3634	0.2743 ★
<b>TFLite (KB)</b>	6.86	8.59	N/A	N/A
<b>Deploy no Pico</b>	SIM ✓	SIM ✓	NÃO ✗	NÃO ✗

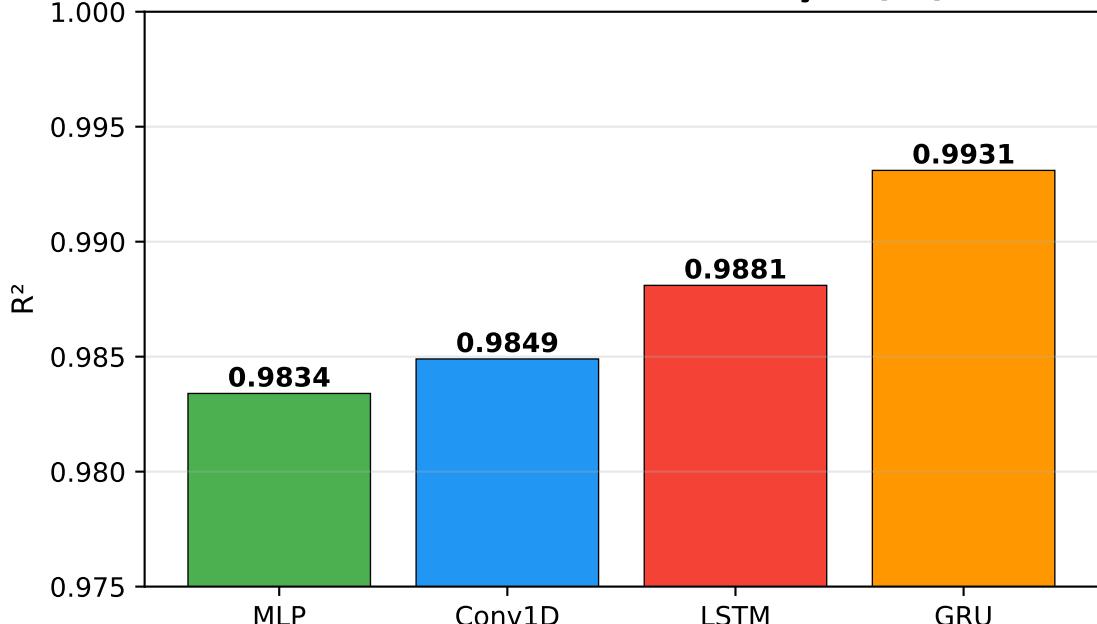
★ = Melhor métrica | ✓ = Compatível com TFLite Micro | ✗ = Incompatível (operações recorrentes)

# Comparação de Métricas entre Arquiteturas

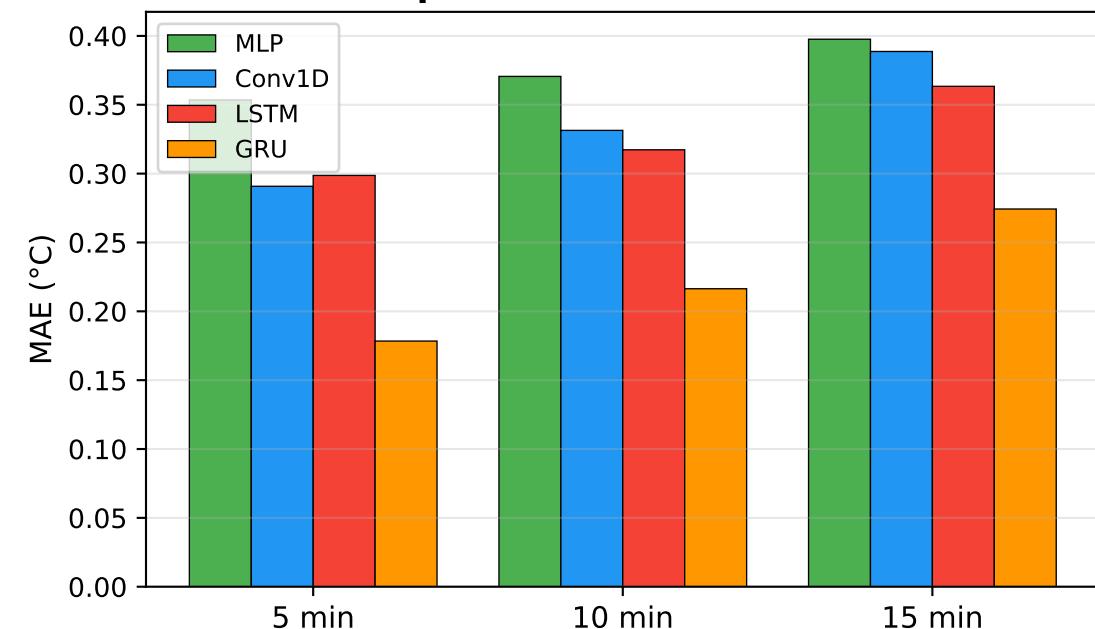
## MAE Geral



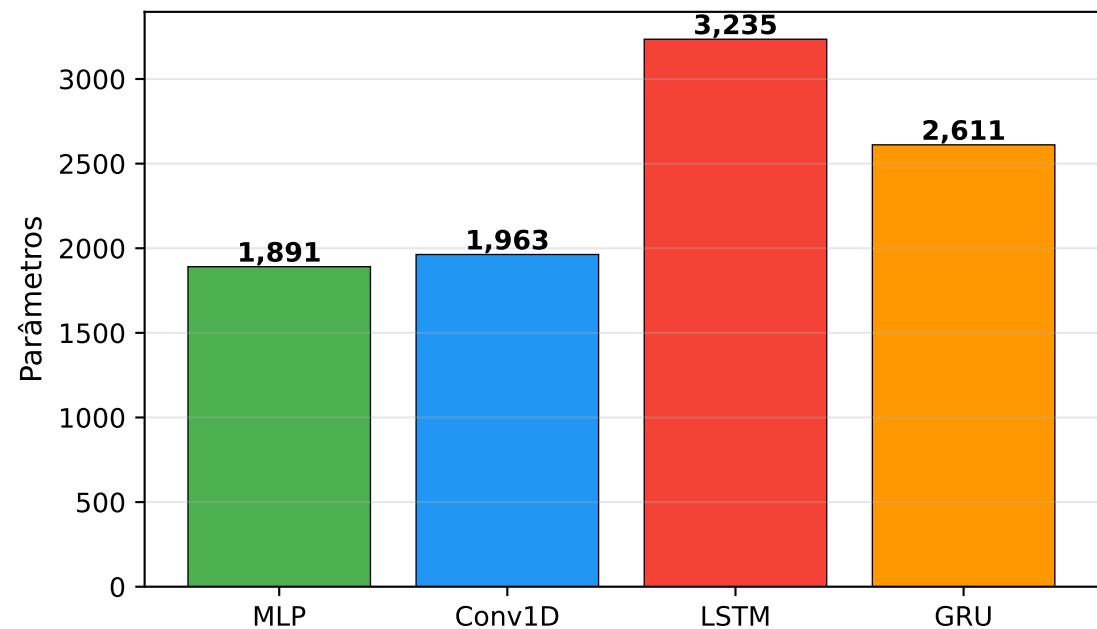
## Coeficiente de Determinação ( $R^2$ )



## MAE por Horizonte de Previsão

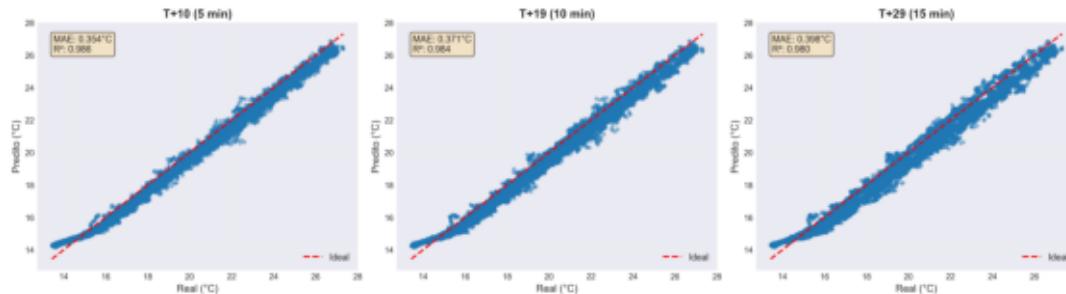


## Total de Parâmetros

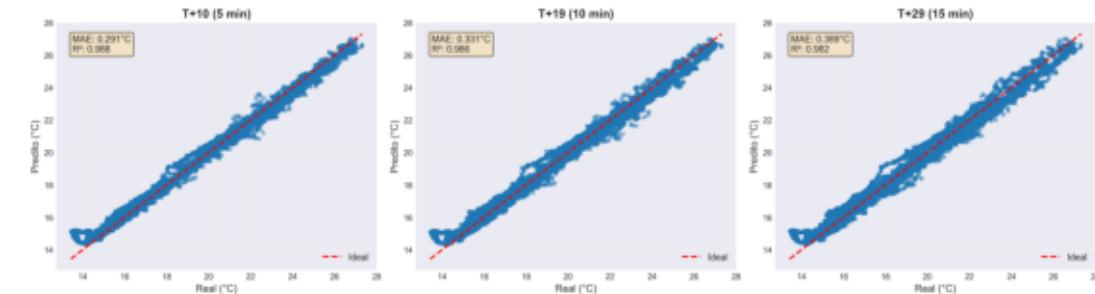


# Predito vs Real - Comparação entre Arquiteturas

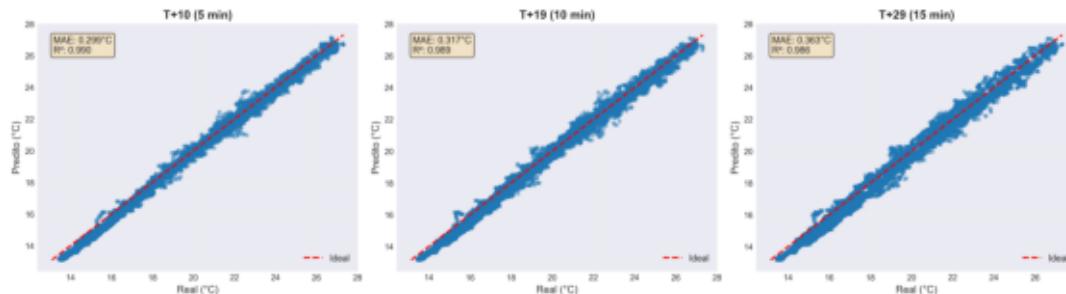
**MLP (MAE:  $0.3739^{\circ}\text{C}$ , R<sup>2</sup>: 0.9834)**



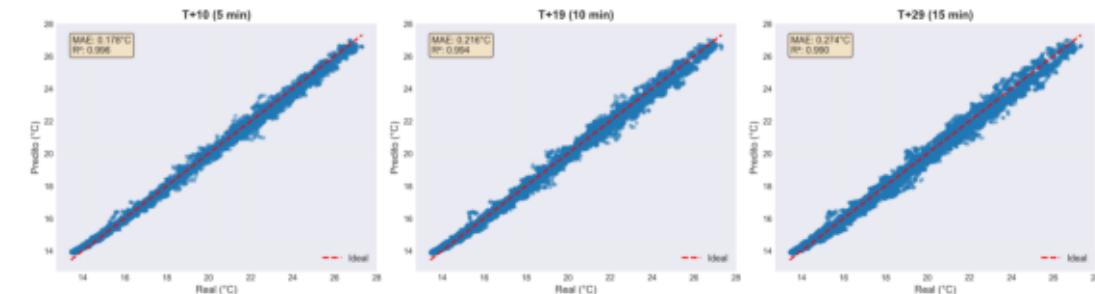
**Conv1D (MAE:  $0.3370^{\circ}\text{C}$ , R<sup>2</sup>: 0.9849)**



**LSTM (MAE:  $0.3264^{\circ}\text{C}$ , R<sup>2</sup>: 0.9881)**

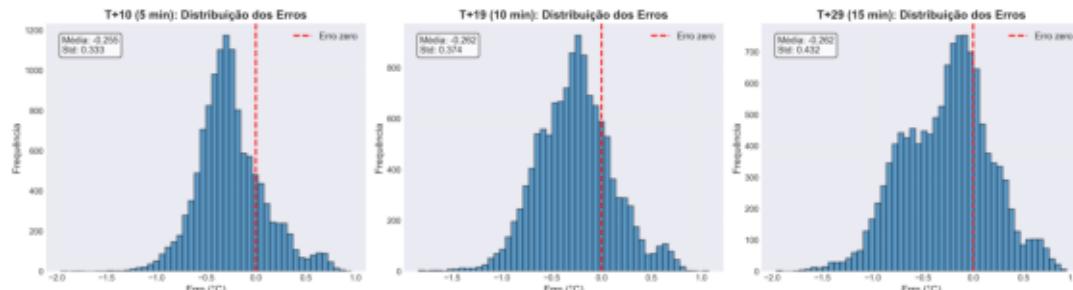


**GRU (MAE:  $0.2230^{\circ}\text{C}$ , R<sup>2</sup>: 0.9931)**

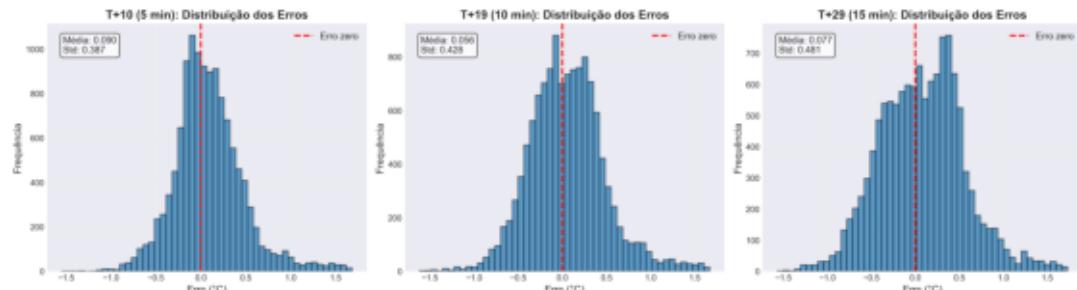


# Distribuição dos Erros - Comparaçao entre Arquiteturas

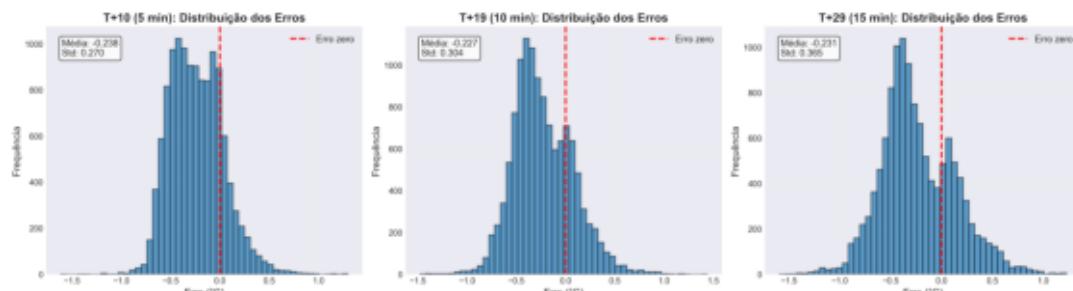
**MLP (MAE: 0.3739°C)**



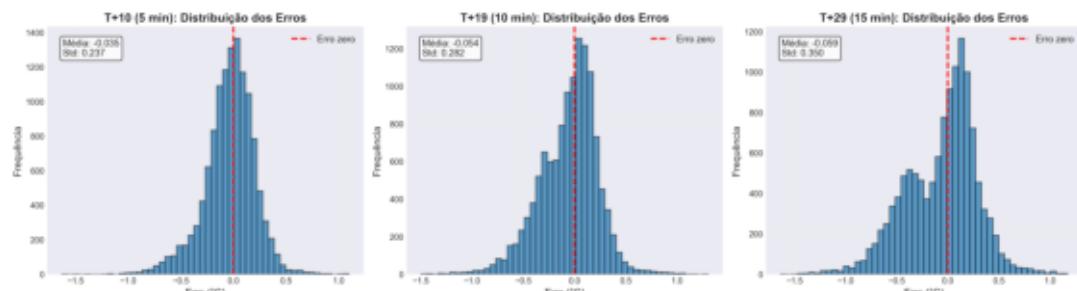
**Conv1D (MAE: 0.3370°C)**



**LSTM (MAE: 0.3264°C)**



**GRU (MAE: 0.2230°C)**



# Análise Comparativa e Justificativa da Escolha

## 1. RANKING POR DESEMPENHO (MAE Geral)

- |            |          |   |
|------------|----------|---|
| 1º GRU:    | 0.2230°C | (melhor precisão, mas NÃO roda no Pico) |
| 2º LSTM:   | 0.3264°C | (boa precisão, mas NÃO roda no Pico)    |
| 3º Conv1D: | 0.3370°C | (roda no Pico via TFLite Micro)         |
| 4º MLP:    | 0.3739°C | (roda no Pico via TFLite Micro)         |

## 2. POR QUE GRU E LSTM NÃO RODAM NO RASPBERRY PI PICO?

As redes recorrentes (GRU e LSTM) utilizam operações internas baseadas em `TensorListReserve` para gerenciar seus estados ocultos ao longo dos timesteps. Essas operações NÃO são suportadas pelo TensorFlow Lite Micro, impossibilitando a conversão do modelo `.keras` para `.tflite`. Ao tentar converter, o erro "failed to legalize operation 'tf.TensorListReserve'" é gerado. Portanto, apesar do melhor desempenho, GRU e LSTM são inviáveis para deploy.

## 3. POR QUE CONV1D FOI ESCOLHIDA (E NÃO MLP)?

Entre os dois modelos deployáveis (Conv1D e MLP), a Conv1D foi escolhida por:

- MAE 9.9% menor que MLP (0.3370 vs 0.3739°C)
- $R^2$  superior (0.9849 vs 0.9834)
- Melhor desempenho em TODOS os horizontes de previsão
- Apenas 72 parâmetros a mais que o MLP (1.963 vs 1.891)
- Modelo TFLite de apenas 8.59 KB (compatível com 2MB Flash do RP2040)
- Conv1D captura padrões temporais locais via filtros convolucionais, enquanto MLP trata features de forma independente (sem noção temporal)

## 4. CONCLUSÃO

A Conv1D apresenta o melhor equilíbrio entre precisão e viabilidade de deploy no RP2040. Com MAE de 0.34°C e apenas 1.963 parâmetros (8.59 KB em TFLite), é capaz de prever temperatura com erro inferior a 0.5°C em horizontes de até 15 minutos, sendo totalmente compatível com TensorFlow Lite Micro.